

Improved Two-Stage CLIP Pipeline for Facial Action Unit Detection

Trình bày đề xuất cho GVHD - học viên cao học ngành Khoa học máy tính

Đối tượng bài toán	Multi-label Action Unit occurrence detection trên DISFA
Trọng tâm mô hình	Learned AU prompts, multi-label ITC, WeightedBCE fine-tuning
Tài liệu nền	Sơ đồ 3 tầng, walkthrough.md, báo cáo khoa học hiện tại, source code
Ngày lập	10/05/2026

Luận điểm trình bày

Mô hình được định vị là một đề xuất cải tiến dựa trên CLIP-ReID/CoOp cho AU detection: học semantic prototypes ở Stage I, sau đó fine-tune detector đa nhãn ở Stage II. Báo cáo không claim SOTA đã được chứng minh khi chưa có kết quả subject-disjoint 3-fold đầy đủ.

1. Mục tiêu và phạm vi mô hình

Mục tiêu của hệ thống là nhận diện sự xuất hiện của 12 Facial Action Units (AUs) trên ảnh khuôn mặt, theo hướng multi-label AU occurrence detection. Mỗi ảnh có thể chứa nhiều AU đồng thời, vì vậy bài toán khác với phân loại một lớp và cũng khác với nhận diện cảm xúc trực tiếp.

Phạm vi hiện tại được giới hạn ở ảnh tĩnh DISFA, nhãn AU nhị phân hóa từ intensity, backbone CLIP ViT-B/16, prompt learning ở phía text và rule-based verbalization ở đầu ra. Lớp verbalization chỉ diễn giải AU thành mô tả hành động mặt; nếu có gợi ý cảm xúc thì chỉ nên hiểu là heuristic, không phải kết luận tâm lý chắc chắn.


- Input: ảnh khuôn mặt x và nhãn AU nhị phân y trong $\{0,1\}^{12}$.
- Output: xác suất AU, tập AU active và mô tả ngôn ngữ ngắn.
- Tiêu chí trình bày: đúng logic code, thuật ngữ thống nhất, có phản biện khoa học.

2. Ký hiệu và thuật ngữ thống nhất

Ký hiệu	Định nghĩa ngắn	Vị trí trong sơ đồ
x	Ảnh khuôn mặt đầu vào	Visual Encoding
y	Vector nhãn AU nhị phân 12 chiều	DISFA label curation
T_{AU}	Semantic prototypes sinh từ learned AU prompts	Semantic AU Prototypes
S	Ma trận affinity ảnh-AU: $\text{norm}(g_i) \text{norm}(T_{AU})^T / \tau$	Stage I
z_f, z_g	Logits từ hai AU heads trên feature chính và projected feature	Stage II
p	Xác suất AU sau sigmoid, $p = \text{sigmoid}(z_f)$	Inference
L_{ITC}	Loss căn chỉnh image-text phụ trợ	Stage I/II
WeightedBCE	BCEWithLogitsLoss có pos_weight theo train fold	Stage II

3. Sơ đồ mô hình theo ba tầng

Sơ đồ được tổ chức theo ba tầng logic: Visual Encoding, Semantic AU Prototypes, và Training & Inference. Các callout I1-I6 là điểm cải tiến hoặc điểm cần nhấn mạnh khi trình bày trước GVHD.



Hình 1. Pipeline đề xuất theo ba tầng cho nhận diện Action Units.

4. Các cải tiến chính theo sơ đồ

Mã	Cải tiến	Ý nghĩa khi bảo vệ đề xuất
I1	Label binarization	Chuyển intensity DISFA thành AU occurrence bằng ngưỡng $a_k \geq 2$; làm rõ mục tiêu học là occurrence detection.
I2	Learned AU prompts	Dùng learnable tokens thay cho mô tả AU cố định; cho phép CLIP thích nghi với downstream AU space.
I3	Multi-label ITC	Một ảnh có thể align với nhiều AU prototypes cùng lúc, phù hợp bản chất đồng xuất hiện của AUs.
I4	Sequential optimization	Tách học semantic prototypes ở Stage I và học classifier thị giác ở Stage II để ổn định huấn luyện.
I5	Imbalance-aware training	Dùng pos_weight theo train fold để giảm thiên lệch do AU hiếm trong DISFA.
I6	Interpretable output	Giữ đầu ra vừa định lượng vừa có mô tả hành động mặt, nhưng không diễn giải cảm xúc như kết luận tuyệt đối.

5. Logic huấn luyện và suy luận

Stage I - Prompt Alignment Ảnh được mã hóa thành g_i, prompt AU được mã hóa thành T_{AU}. Hệ thống tính $S = \text{norm}(g_i) \text{norm}(T_{AU})^T / \tau$ và tối ưu $L_1 = \text{BCEWithLogits}(S, y)$. Optimizer Stage I chỉ cập nhật prompt_learner.
Stage II - AU Fine-Tuning Text side được đóng băng. Backbone CLIP ViT-B/16, BNNeck và hai AU heads được fine-tune bằng $\text{WeightedBCE}(\{z_f, z_g\}, y) + 0.1 L_{ITC}$. Thành phần L_{ITC} giữ ràng buộc image-text từ Stage I.
Inference - Decision and Explanation Ở eval/inference, code dùng $p = \text{sigmoid}(z_f)$ và quyết định $hat_y_k = 1[p_k > 0.5]$. Vector AU active được đưa sang rule-based verbalization để sinh mô tả hành động mặt.

6. Phân tích phản biện của GVHD

Góc nhìn	Nhận xét học thuật	Cách trình bày thận trọng
Điểm mạnh	Tận dụng CLIP/ViT pretrained, prompt learning và two-stage training cho AU occurrence.	Gọi là đề xuất cải tiến dựa trên CLIP-ReID/CoOp, không gọi là SOTA đã chứng minh.
Dữ liệu	Subject-disjoint 3-fold và pos_weight theo train fold giúp giảm leakage và lệch lớp.	Cần báo cáo mean/std qua folds trước khi kết luận benchmark.
Giới hạn mô hình	Feature hiện tại là global CLIP/ViT; chưa có landmark, AU-region attention hoặc temporal modeling.	Nêu đây là phạm vi code hiện tại và là hướng nâng cấp tiếp theo.
Giải thích	Verbalization minh bạch nhưng rule-based; emotion hint chỉ là heuristic.	Dùng từ “gợi ý/cho thấy xu hướng”, tránh khẳng định trạng thái cảm xúc.
Threshold	Ngưỡng $p > 0.5$ đơn giản và reproducible nhưng chưa calibration theo từng AU.	Đề xuất threshold calibration trên validation fold như future work.

7. Kết luận đề xuất

Mô hình đề xuất có logic phù hợp cho một buổi trình GVHD: bắt đầu từ bài toán AU occurrence, dùng CLIP để học semantic prototypes, sau đó fine-tune detector đa nhãn bằng loss có xử lý mất cân bằng. Điểm mạnh của thiết kế là rõ ràng về pipeline, có lớp diễn giải đầu ra và có các điểm cải tiến I1-I6 gắn trực tiếp vào sơ đồ. Điểm cần tiếp tục là chứng minh thực nghiệm bằng subject-disjoint 3-fold, calibration theo AU và mở rộng sang region-aware hoặc temporal modeling.

References

- [1] P. Ekman, W. V. Friesen, and J. C. Hager, Facial Action Coding System: The Manual on CD ROM. Salt Lake City, UT, USA: A Human Face, 2002.
- [2] S. M. Mavadati, M. H. Mahoor, K. Bartlett, P. Trinh, and J. F. Cohn, "DISFA: A spontaneous facial action intensity database," IEEE Transactions on Affective Computing, vol. 4, no. 2, pp. 151-160, 2013.
- [3] A. Radford et al., "Learning transferable visual models from natural language supervision," in Proc. ICML, 2021, pp. 8748-8763.
- [4] A. Dosovitskiy et al., "An image is worth 16x16 words: Transformers for image recognition at scale," in Proc. ICLR, 2021.
- [5] K. Zhou, J. Yang, C. C. Loy, and Z. Liu, "Learning to prompt for vision-language models," International Journal of Computer Vision, vol. 130, pp. 2337-2348, 2022.
- [6] S. Li, L. Sun, and Q. Li, "CLIP-ReID: Exploiting vision-language model for image re-identification without concrete text labels," in Proc. AAAI, 2023.
- [7] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in Proc. ICML, 2015.
- [8] Z. Shao, Z. Liu, J. Cai, and L. Ma, "Facial action unit detection using attention and relation learning," arXiv:1808.03457, 2018.