


EmotionCLIP-ReID: Hướng Tiếp Cận Tổng Hợp để Nhận Dạng Cảm Xúc Bền Bĩ

Vượt qua Thử thách Che khuất và Đa góc nhìn bằng cách tích hợp tri thức từ các mô hình Vision-Language tiên tiến.



Bài toán Nhận dạng Cảm xúc (FER) trong Thế giới Thực: Không chỉ là những khuôn mặt chính diện, rõ nét

Các hệ thống FER hiện tại hoạt động tốt trong điều kiện phòng thí nghiệm, nhưng hiệu suất giảm đáng kể khi đối mặt với dữ liệu thực tế phức tạp.

Thách thức 1: Che khuất (Occlusion)

Kính mắt, khẩu trang, tóc, hoặc các vật thể khác che khuất các vùng đặc trưng quan trọng của khuôn mặt (mắt, miệng), làm mất thông tin cần thiết cho việc nhận dạng.



Thách thức 2: Đa góc nhìn (Multi-view) & Biến dạng Tư thế

Các góc nhìn không chính diện làm thay đổi hình dạng và sự xuất hiện của các đặc điểm trên khuôn mặt, gây khó khăn cho các mô hình vốn được huấn luyện chủ yếu trên ảnh chính diện.



Xây dựng trên nền tảng của những người khổng lồ: Các khối kiến thức nền tảng

Để giải quyết các thách thức trên, chúng tôi không bắt đầu từ con số không. Thay vào đó, chúng tôi tổng hợp các ý tưởng đột phá từ những nghiên cứu hàng đầu.



Khung sườn Vững chắc

Nguồn: CLIP-ReID

Cung cấp một kiến trúc huấn luyện 2 giai đoạn đã được chứng minh là hiệu quả để học các biểu diễn hình ảnh (visual representation) dưới sự dẫn dắt của các "mô tả" văn bản được tạo ra một cách linh hoạt, ngay cả khi không có nhãn văn bản cụ thể.



Module Mô tả Vi mô

Nguồn: MER-CLIP


Thay vì dùng nhãn cảm xúc chung chung ("vui"), hãy mô tả các chuyển động vi mô của cơ mặt (Action Units - AU) như "khóe môi được kéo lên". Cách tiếp cận này bền bỉ hơn khi một phần khuôn mặt bị che.



Module Hiệu chỉnh Bất định

Nguồn: UA-FER

Các biểu cảm có thể mơ hồ. Thay vì đưa ra một dự đoán "quá tự tin", mô hình nên có khả năng nhận biết và định lượng sự không chắc chắn của mình, sử dụng Evidential Deep Learning (EDL) để tăng độ tin cậy.



Module Thích ứng Linh hoạt


Nguồn: EA-CLIP

Sử dụng các module 'Adapter' gọn nhẹ là một cách hiệu quả để tinh chỉnh các mô hình lớn như CLIP cho các tác vụ cụ thể, giúp giữ lại kiến thức tổng quát và tăng hiệu suất tính toán.

Nền tảng Kiến trúc: CLIP-ReID và Chiến lược Huấn luyện Hai Giai đoạn

Vấn đề của ReID: Trong bài toán Re-Identification, nhận là các chỉ số (ID 1, ID 2) chứ không phải văn bản mô tả, gây khó khăn cho việc áp dụng trực tiếp CLIP.

Giải pháp của CLIP-ReID: Một chiến lược thông minh để 'tạo ra' các mô tả văn bản có thể học được.



Hiệu quả được chứng minh: Trực quan hóa không gian đặc trưng


Biểu đồ t-SNE cho thấy sự phân bố của các đặc trưng hình ảnh (chấm tròn) và đặc trưng văn bản (ngôi sao) của 10 người được chọn ngẫu nhiên.

Sau Giai đoạn 1: Các Mô tả Văn bản 'Tìm đến' Hình ảnh



Các đặc trưng hình ảnh (chấm tròn) vẫn còn phân tán. Tuy nhiên, các đặc trưng văn bản (ngôi sao) đã học được đã di chuyển đến trung tâm của các cụm hình ảnh tương ứng. Các ngôi sao màu khác nhau đại diện cho các 'mô tả' đã học cho mỗi ID.

Sau Giai đoạn 2: Hình ảnh 'Co cụm' quanh Mô tả Văn bản




Dưới sự 'dẫn dắt' của các đặc trưng văn bản cố định, các đặc trưng hình ảnh của cùng một người đã co cụm lại một cách rõ rệt. Các cụm khác nhau trở nên tách biệt, cho thấy mô hình đã học được các biểu diễn có tính phân loại cao.

Kiến trúc hai giai đoạn này là một 'khung sườn' mạnh mẽ để điều chỉnh các biểu diễn hình ảnh theo các khái niệm ngữ nghĩa được học.

Tổng hợp các Mảnh ghép: Giới thiệu EmotionCLIP-ReID

Chúng tôi đề xuất **EmotionCLIP-ReID**, một kiến trúc mới kế thừa khung sườn 2 giai đoạn của CLIP-ReID và tích hợp các module chuyên dụng để nhận dạng cảm xúc bền bỉ.





Chi tiết Giai đoạn 1: Học 'Mô tả Cảm xúc' theo Ngữ cảnh

Mục tiêu: Tạo ra các vector đặc trưng văn bản (text embeddings) có khả năng phân biệt cao và giàu thông tin cho từng loại cảm xúc, đặc biệt là phải bền bỉ trước tình trạng che khuất.


1. Cố định Encoders

Giữ nguyên trọng số của Image Encoder và Text Encoder từ CLIP đã được tiền huấn luyện.



2. Thiết kế Prompt có Cấu trúc (Structured Prompt Design)


Sử dụng các prompt kết hợp nhãn cảm xúc với các token có thể học được, lấy cảm hứng từ MER-CLIP.



Các token `[X]m` sẽ học cách mã hóa các đặc điểm hình ảnh tinh vi liên quan đến cảm xúc "surprise" (ví dụ: lông mày nhướn lên, miệng há ra).

3. Tối ưu hóa bằng Contrastive Loss

Trong một batch, các cặp (ảnh, prompt đúng) sẽ được kéo lại gần nhau trong không gian đặc trưng. Các cặp (ảnh, prompt sai) sẽ bị đẩy ra xa. Chỉ các token `[X]m` được cập nhật trong quá trình này.




Kết quả của Giai đoạn 1: Một bộ 'Emotion Descriptors' - các vector đặc trưng văn bản - đã được tối ưu hóa, nắm bắt được bản chất hình ảnh của từng loại cảm xúc.

Chi tiết Giai đoạn 2: Tinh chỉnh Bộ mã hóa Hình ảnh Thông minh và Bền bỉ

Mục tiêu: Điều chỉnh Image Encoder để nó có thể ánh xạ các hình ảnh khuôn mặt (kể cả bị che khuất, đa góc nhìn) đến đúng "Emotion Descriptor" tương ứng đã học ở Giai đoạn 1.

1. Cố định Text Pipeline


Giữ nguyên Text Encoder và các Emotion Descriptors đã học. Chúng giờ đây là "chân lý" (ground truth) về mặt ngữ nghĩa.



2. Tinh chỉnh Hiệu quả với Adapter (EA-CLIP)

Thay vì cập nhật hàng triệu tham số của toàn bộ Image Encoder (ViT), chúng tôi chỉ chèn và huấn luyện các module **Adapter** gọn nhẹ.

- **Lợi ích:** Giảm nguy cơ overfitting, giữ lại kiến thức tổng quát quý giá từ CLIP, và tăng tốc độ huấn luyện.



3. Tăng cường Bền bỉ với Uncertainty Loss (UA-FER)

Hàm mất mát tổng hợp

$$\mathcal{L}_{\text{stage2}} = \mathcal{L}_{\text{classification}} + \mathcal{L}_{\text{contrastive}} + \lambda * \mathcal{L}_{\text{uncertainty}}$$



Kết quả của Giai đoạn 2: Một Image Encoder chuyên biệt cho FER, có khả năng khái quát hóa tốt và đáng tin cậy hơn trong các điều kiện khó.

Ưu điểm Vượt trội của EmotionCLIP-ReID

Bằng cách tích hợp các ý tưởng tốt nhất, EmotionCLIP-ReID được thiết kế để giải quyết các điểm yếu cố hữu của các phương pháp trước đây.



Khả năng chống chịu Che khuất Cao

Nhờ việc học các mô tả dựa trên đặc điểm vi mô (MER-CLIP), mô hình có thể nhận dạng cảm xúc ngay cả khi chỉ một vài vùng đặc trưng (như mắt hoặc miệng) có thể nhìn thấy.




Xử lý Tốt Dữ liệu Đa góc nhìn và Mơ hồ

Cơ chế hiệu chỉnh bất định (UA-FER) giúp mô hình đưa ra quyết định đáng tin cậy hơn đối với các mẫu khó, nằm ở ranh giới giữa các lớp cảm xúc, thường gặp ở các góc nhìn không chính diện.



Hiệu quả về Tham số và Giữ lại Tri thức Nền tảng

Việc sử dụng Adapter (EA-CLIP) để tinh chỉnh giúp bảo toàn khả năng khái quát hóa mạnh mẽ của CLIP gốc, tránh hiện tượng "catastrophic forgetting" và tiết kiệm tài nguyên tính toán.



Kiến trúc có Hệ thống và Dễ mở rộng

Dựa trên khung sườn 2 giai đoạn đã được kiểm chứng của CLIP-ReID, phương pháp này cung cấp một quy trình huấn luyện rõ ràng, có hệ thống và có thể dễ dàng tích hợp thêm các cải tiến trong tương lai.

Lộ trình Triển khai và Đánh giá

Mục tiêu: Chứng minh một cách định lượng rằng EmotionCLIP-ReID vượt trội hơn các phương pháp state-of-the-art, đặc biệt là trên các tập dữ liệu có chứa các mẫu bị che khuất và đa góc nhìn.




Xây dựng Baseline

Triển khai lại các phương pháp cốt lõi: CLIP-ReID (chỉnh sửa cho bài toán phân loại), EA-CLIP, UA-FER trên cùng một bộ dữ liệu để có sự so sánh công bằng.




Tập dữ liệu (Datasets)

- **Tập tiêu chuẩn 'In-the-wild':** RAF-DB, AffectNet. Các tập này chứa sự đa dạng về tư thế, ánh sáng và biểu cảm tự nhiên.
- **Tập có kiểm soát về Thử thách:** Sử dụng các phiên bản đã được xử lý của RAF-DB và AffectNet để đánh giá riêng biệt hiệu suất trên dữ liệu bị che khuất (Occlusion-RAF-DB) và dữ liệu có góc nhìn thay đổi (Pose-RAF-DB), như đã được thực hiện trong các nghiên cứu của EA-CLIP và UA-FER.



Các chỉ số đánh giá (Metrics)

- Độ chính xác tổng thể (Overall Accuracy).
- Ma trận nhầm lẫn (Confusion Matrix) để phân tích các lỗi cụ thể giữa các lớp cảm xúc.
- Độ chính xác trên từng tập con (che khuất, góc $>30^\circ$, góc $>45^\circ$) để chứng minh sự bền bỉ.




Phân tích Trực quan hóa

Sử dụng các phương pháp như Grad-CAM để trực quan hóa các vùng mà mô hình tập trung vào, nhằm chứng minh rằng EmotionCLIP-ReID chú ý đến các vùng cơ mặt phù hợp.

EmotionCLIP-ReID: Một Hướng đi Mới, Toàn diện cho Nhận dạng Cảm xúc Thực tế Thực tế

Tóm tắt Lập luận

- **Vấn đề:** Các hệ thống FER hiện tại rất mong manh trước các thách thức thực tế như che khuất và đa góc nhìn.
- **Phân tích:** Các nghiên cứu đơn lẻ đã cung cấp những mảnh ghép quý giá—mô tả vi mô, hiệu chỉnh bất định, tinh chỉnh hiệu quả—nhưng chưa có một giải pháp tổng hợp.
- **Đề xuất:** EmotionCLIP-ReID là một kiến trúc được thiết kế có chủ đích, tích hợp các mảnh ghép này vào một khung sườn huấn luyện 2 giai đoạn mạnh mẽ, đã được chứng minh.



Tầm nhìn

Phương pháp này không chỉ hứa hẹn cải thiện độ chính xác, mà còn tạo ra các mô hình AI hiểu cảm xúc một cách đáng tin cậy và có khả năng diễn giải cao hơn, mở đường cho các ứng dụng thực tiễn trong tương tác người-máy, phân tích hành vi và sức khỏe tinh thần.